

## Hey, Chat!

### Introducción

*Hey Banco* es una aplicación digital que funciona igual que un banco. Uno de los principales objetivos subyacentes en la empresa es la formación de experiencias que, consecuentemente produzcan una retención de clientes y la generación de valor. El diseño de tarjetas personalizadas para ciertos eventos, como el Pal Norte, justifican este enfoque que se tiene en el banco.

Es por ello mismo, que el reto de este banco, se remite a un pronóstico que sea capaz de ofrecer una buena idea de los gastos futuros en el tiempo que se necesite. De esta forma, la opción más viable para un modelo se reduce a aquellos especializados de crear un *Forecast*.

### Realización del proyecto

Anteriormente se mencionó el uso de modelos especializados en *Time Series Forecast*, en este ámbito se decidió desarrollar dos modelos, con el objetivo de poder comparar sus outcomes y decidir en base a ello el modelo que tomará el centro de este proyecto. Estos dos modelos eran; *VertexAI* (Google) y *Prophet* (Meta).

Para la realización del modelo se usaron dos bases de datos proporcionada por el banco; sobre los clientes, y sobre las compras individuales de un cliente a lo largo de un año y 29 días. La base de datos fue modificada para ser usada como entrenamiento, siendo por ejemplo aquellas columnas que demostraban una oscilación entre dos valores aquellas que se cambiaron por un valor booleano apto para el entrenamiento, o el uso de categorías para conversión a indicadores.

Las pruebas de los modelos se realizaron con un entrenamiento de un año y testeo de 29 días, los resultados fueron posteriormente comparados con los resultados reales y comparados con el resultado MAE y MAPE, se optó por el uso del modelo creado con *Vertex*.

### Descripción del Modelo y predicciones:

El modelo toma como entrenamiento ambas bases de datos en un rango de un año, para poder obtener un análisis completo. La información relevante para la predicción del usuario es la misma que se encuentra en la base de datos de los clientes; ID, fecha de nacimiento, fecha de adquisición de la tarjeta, ID del municipio, ID del estado, tipo de persona (Actividad empresarial o no), género y tipo actividad empresarial. Los datos cumplen un rango de un mes, y generan una predicción. El resultado final demuestra la predicción por usuario de las compras futuras que podría tener en un día anteriormente asignado por el cliente. Características como el comercio, referenciando al lugar en el que esta transacción fue lograda, son calculados a través de umbrales que en base al usuario, retorna una estimación del comercio en base a las compras predichas.

Fecha predicción	Predicción del monto
Jan 18, 2023	57.6263236999512
Jan 18, 2023	75.2274551391602
Jan 5, 2023	40.8904228210449
Jan 5, 2023	38.732723236084

### Limitaciones y posibles mejoras:

Entre las limitaciones se encuentran; resultados inexactos debido a las limitaciones del ML, y una difícil interpretación de los mismos. Las posibles mejoras se encuentran en esta área, puesto que la exactitud puede mejorar en gran medida con una mayor base de datos con variables relevantes. Aun así, la proposición de un modelo exacto, puede llegar a ser imposible debido a la cantidad de variables externas que se omitirían en la caracterización de un cliente mediante variables categóricas y/o numéricas.

Entre los modelos que podrían asemejarse al funcionamiento expuesto en este proyecto, se encuentra el modelo Amazon Forecast, capaz de usar *Big Data*. Según la página descriptiva del modelo, se asegura que el Forecast de esta compañía es rápido y fácil de usar. Uno de los aspectos en los que se diferencia es el enfoque que se tiene uno del otro, puesto que Amazon Forecast tiene como principal enfoque la predicción en una empresa, mientras que el proyecto propuesto es desarrollado para una evaluación principalmente individual.